Introdução ao Tensorflow

X Jornada de Educação, Ciência e Tecnologia (JECT)

Felipe Augusto Lima Reis

felipe.reis@ifmg.edu.br

Agenda

Contexto

Contexto

- Nos últimos 5 anos, as redes neurais artificiais se tornaram extremamente populares;
- *Deep learning*[1] tornou-se um termo bastante conhecido, especialmente a partir de 2014.

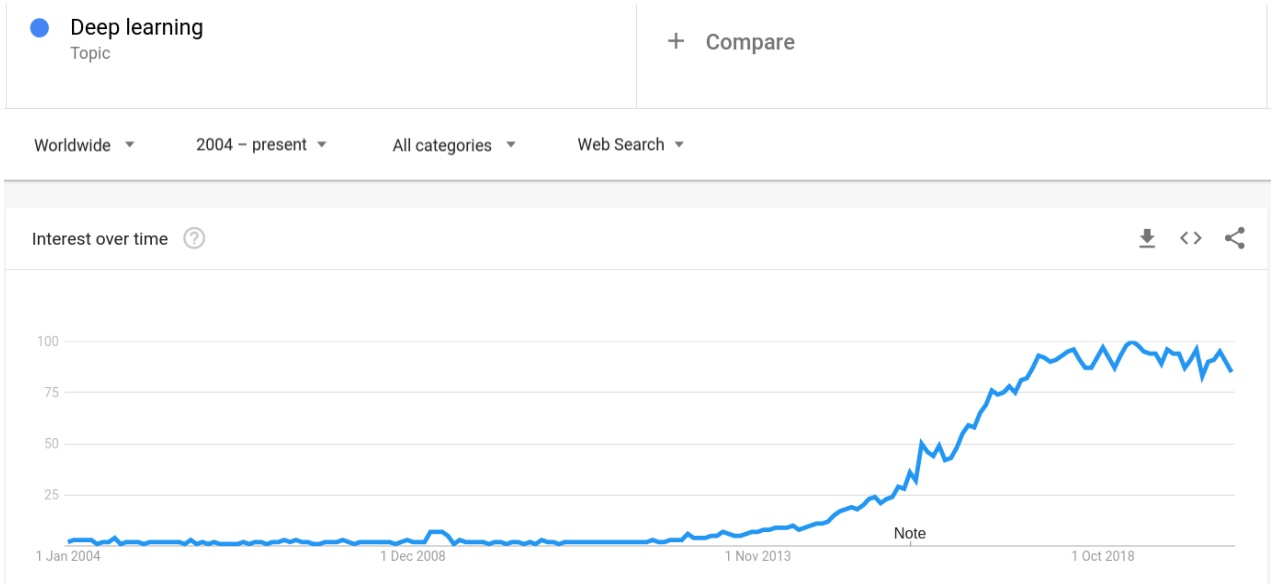

Fonte: [Google Trends, 2020]

[1] Engloba, entre outros, *deep neural networks*, *recurrent neural networks* e *convolutional neural networks*

Contexto

- Redes Neurais podem ser utilizadas para:
  - Tradução automática;
  - Assistentes virtuais;
  - Processamento de linguagem natural;
  - Visão computacional;
  - Suporte ao diagnóstico médico;
  - Detecção de fraudes;
  - Predição de desastres naturais;
  - Sistemas de recomendações;
  - Veículos autônomos;
  - ...

Contexto

- Um dos eventos responsável por essa popularização das redes neurais foi o desempenho da rede AlexNet na detecção e classificação de objetos no ILSVRC[2] 2012
  - A rede diminuiu o erro das top-5 classes previstas em mais de 10% [Goodfellow et al., 2016] [Krizhevsky et al., 2012].

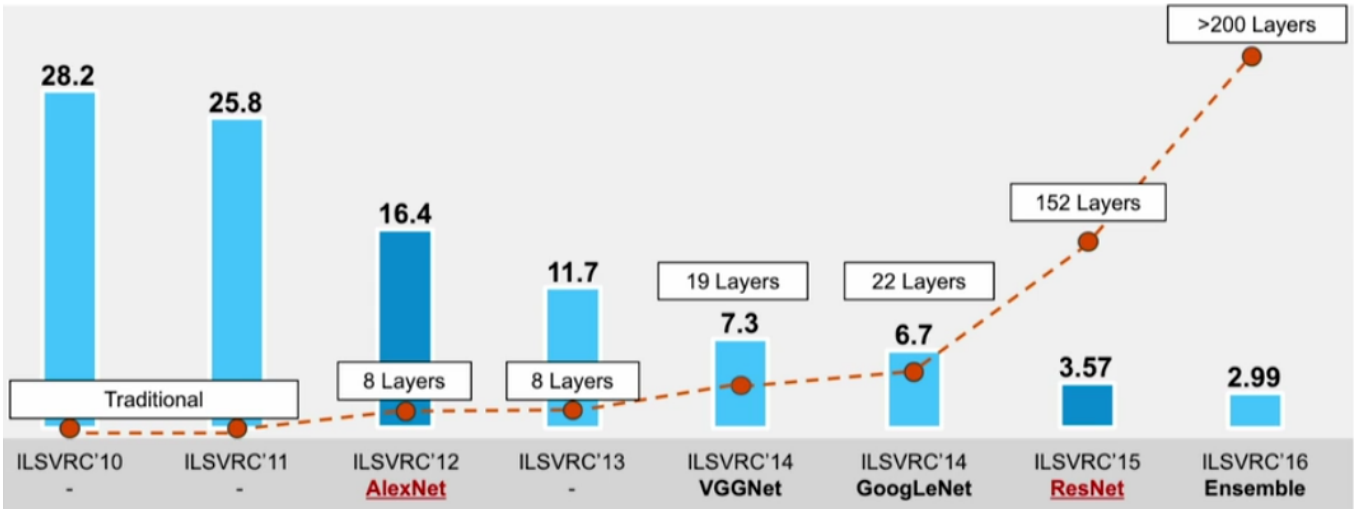

Fonte: [Sadek Alaoui - SQLML, 2017]

[2] ImageNet Large Scale Visual Recognition Challenge (ILSVRC).

Tensorflow

- Tal desempenho levou a um aumento de pesquisas relacionadas às redes neurais;
- Consequentemente, ferramentas e frameworks começaram a ser desenvolvidos para facilitar o treinamento e o uso das redes
  - Tais ferramentas implementavam algoritmos complexos e forneciam mecanismos simplificados para processamento das redes neurais em GPUs;
  - Diversas ferramentas surgiram, como o Theano, Tensorflow, Caffe, PyTorch e o CNTK.

Tensorflow

- Tensorflow é uma plataforma aberta e open-source para criação e implantação de modelos de Aprendizado de Máquina [Abadi et al., 2015]
  - A ferramenta surgiu em 2015 a partir de uma evolução do projeto DistBelieve, desenvolvido pela Google Brain;
  - Foi lançado sob a licença Apache 2.0;

Fonte: [Abadi et al., 2015]

Tensorflow

- O nome Tensorflow está associado a dois conceitos importantes, que podem ser associados ao fluxo de informações em uma rede neural
  - Tensor: generalização da noção de escalares, vetores e matrizes;
  - Dataflow: paradigma de programação que modela um programa como um grafo direcionado do fluxo de dados entre as operações.

Tensorflow

- Atualmente o Tensorflow está na versão (estável) 2.6.0;
  - A versão 2.0 foi lançada em 2019 e contém muitas modificações em relação à primeira versão;
- Existe ainda uma versão denominada Tensorflow Lite, lançada em 2017 e destinada especificamente aos dispositivos móveis.

Keras

- Keras é uma biblioteca de código aberto que fornece uma interface Python para redes neurais artificiais
  - O Keras foi desenvolvido para facilitar o trabalho com ferramentas de aprendizado profundo;
  - Lançado em 2015, suportava back-ends TensorFlow, CNTK, Theano e PlaidML;
  - A partir da versão 2.4, lançada em 2020, o Keras restringiu seu suporte somente ao Tensorflow.

Fonte: [Chollet, 2015]

Outros Frameworks

- A figura abaixo contém uma linha do tempo dos frameworks de aprendizado profundo.

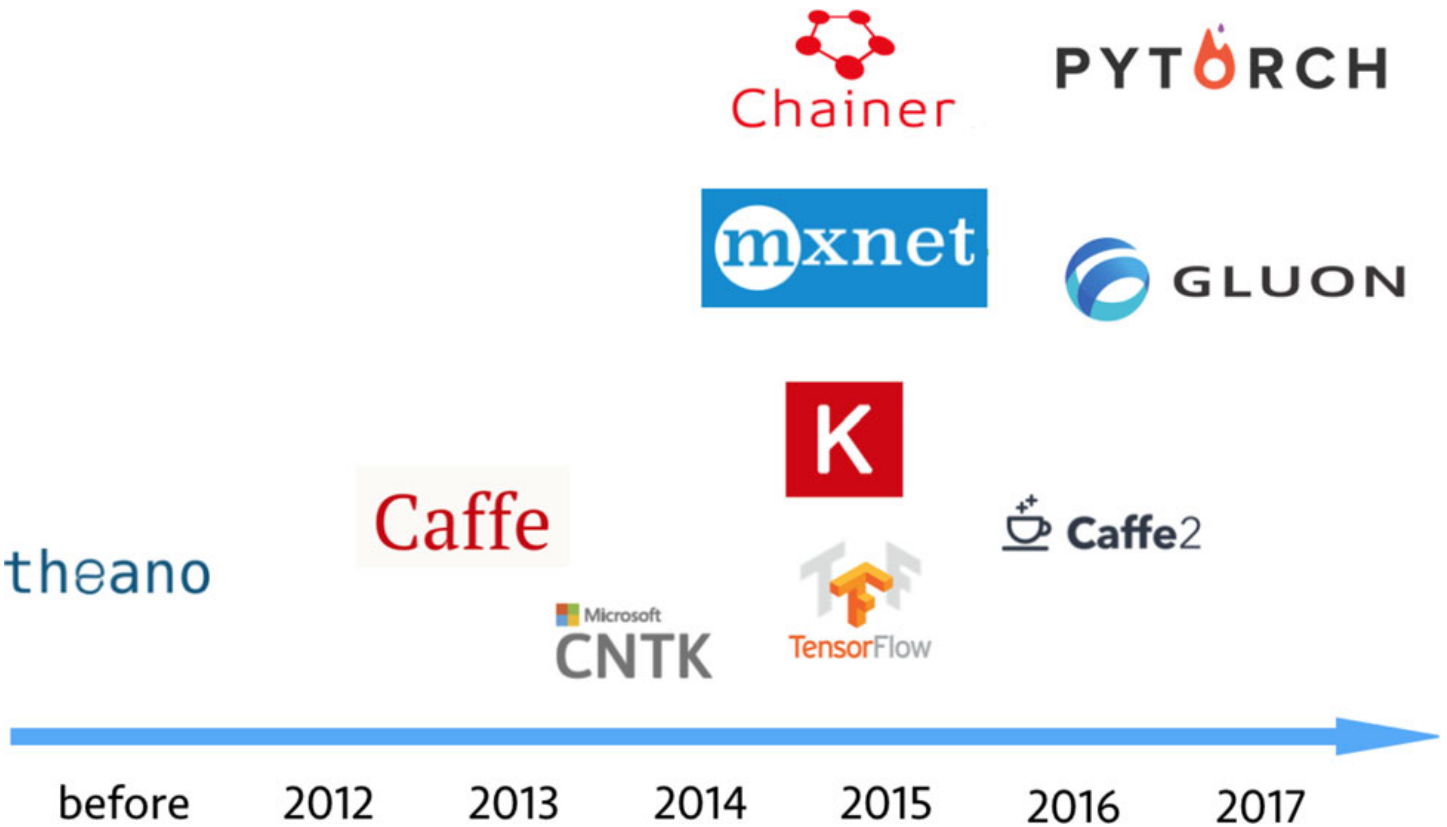

Fonte: [Elshawi et al., 2021]

Outros Frameworks

- A tabela abaixo contém uma comparação entre os frameworks.

	TensorFlow	Keras	PyTorch	MXNet	Theano	Chainer
Release date	2016	2015	2017	2015	2010	2015
Core language	C++	Python, R	C++, Python	C++	C++	Python
API	C++, Python	Python	Python	C++, Python, R Scala, Clojure Javascript, Web-UI	Python	Python
Data parallelism	✔	✔	✔	✔	✔	✔
Model parallelism	✔	✔	✔	✔	✔	✔
Programming paradigm	Imperative	Imperative	Imperative	Imperative declarative	Imperative	Imperative
Fault tolerance	Checkpoint-and -recovery	Checkpoint- and -resume	Checkpoint- and -resume	Checkpoint-and -resume	Checkpoint- and -resume	Checkpoint- and -resume
Multi GPU	✔	✔	✔	✔	✔	✔
Popularity (# stars on Github)	138k	45.8k	34.2k	18.1k	9k	5.2k

Fonte: [Elshawi et al., 2021]

Popularidade dos Frameworks

- A popularidade do frameworks para projetos no Github está disponível na imagem abaixo [Hale, 2018].

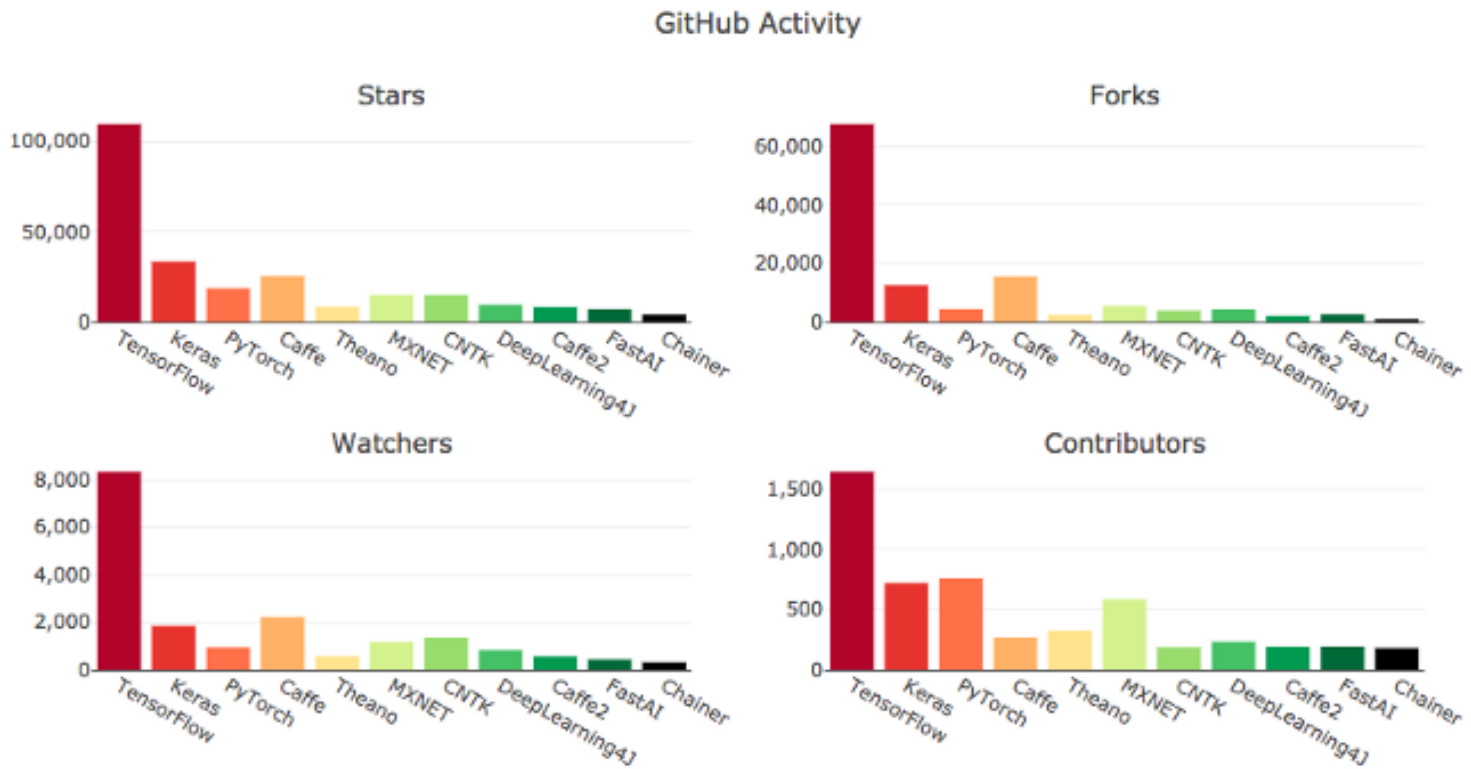

Fonte: [Hale, 2018]

Popularidade dos Frameworks

- A popularidade do frameworks segundo uma pesquisa do site de *data sciente* KDNuggets está disponíve abaixo [Piatetsky, 2018] [Hale, 2018].

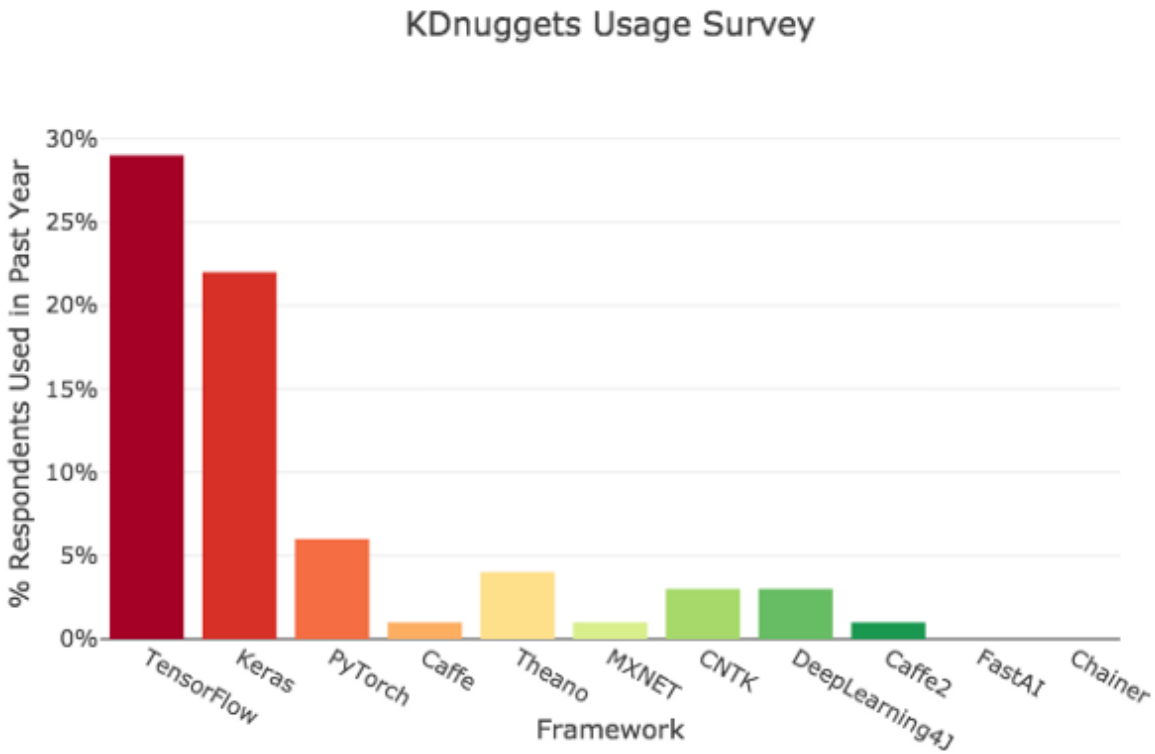

Fonte: [Piatetsky, 2018]

Redes Neurais

Neurônios Artificiais

Neurônios artificiais

- Neurônios artificiais correspondem a um modelo matemático simples, desenvolvido McCulloch e Pitts, em 1943 [Russel and Norvig, 2013] [Coppin, 2004];
- Eles disparam uma combinação linear de suas entradas quando algum limiar é excedido [Russel and Norvig, 2013].

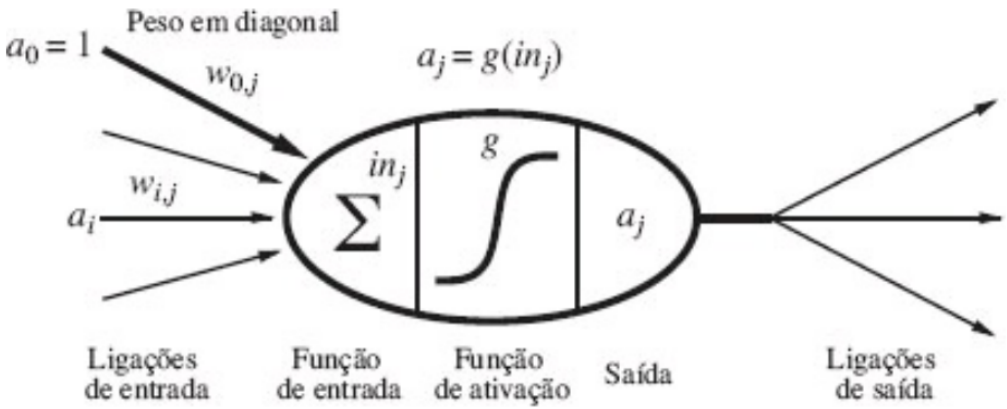

Fonte: [Russel and Norvig, 2013]

Neurônios Artificiais

- O modelo de neurônio proposto por McCulloch e Pitts (1943) pode ser dividido nas seguintes partes:
  - Entrada: sinais $\{x_1, x_2, ..., x_n\}$ oriundos do ambiente externo;
  - Pesos Sinápticos (w_i): utilizado para definição de "importância" ou "relevância" das entradas para o neurônio;
  - Bias (w_b): entrada extra, utilizada para aumentar o grau de liberdade dos ajustes dos pesos;
  - Corpo: soma os produtos das entradas e pesos ($x_i \times w_i$) com o bias (w_b) e aplica a função de ativação;
  - Função de Ativação: controla o comportamento do sinal da saída $f(x)$, limitando o intervalo de valores de saída.

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
  1. Cada neurônio possui um sinal de entrada x_i;
  2. Esse neurônio i liga-se a outro neurônio j e é capaz de propagar um valor de ativação x_i;
  3. Cada ligação tem um peso numérico $w_{i,j}$ associado;

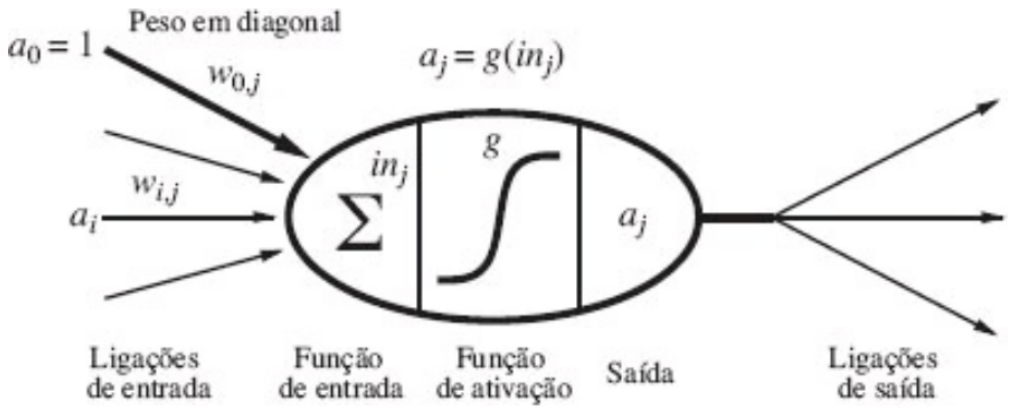

Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
  4. O potencial de ativação de um neurônio é dado pela soma ponderada dos sinais de entrada, somado ao bias (w_b);

$$in_j = \sum_{i=1}^{n} (x_i \cdot w_i) + w_b$$

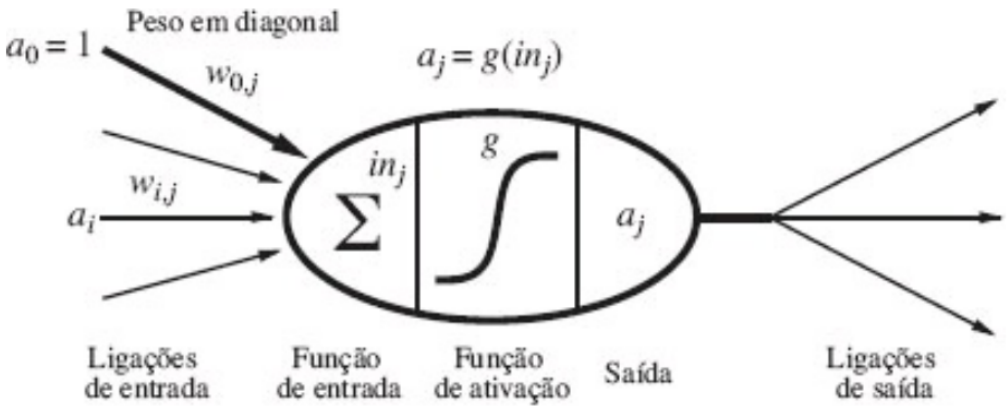

Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Funcionamento de um Neurônio Artificial

- Funcionamento de um neurônio:
  5. Em seguida, é aplicada uma função de ativação g a essa soma, com objetivo de limitar o sinal de saída.

$$x_j = g\left(\sum_{i=1}^{n}(x_i \cdot w_i) + w_b\right)$$

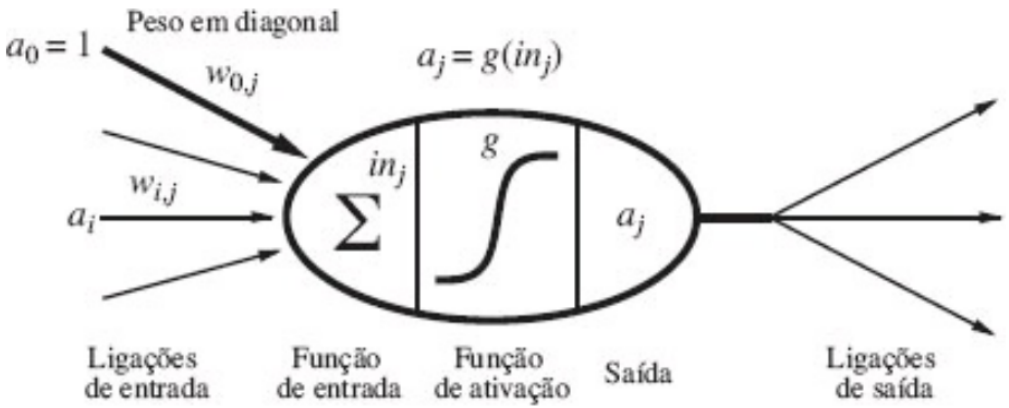

Fonte: [Russel and Norvig, 2013]

Baseado em [da Silva, 2014] e [Russel and Norvig, 2013]

Redes neurais artificiais

- Uma rede neural é apenas uma coleção de neurônios
  - Suas propriedades são determinadas pela topologia e pelos próprios neurônios [Russel and Norvig, 2013].

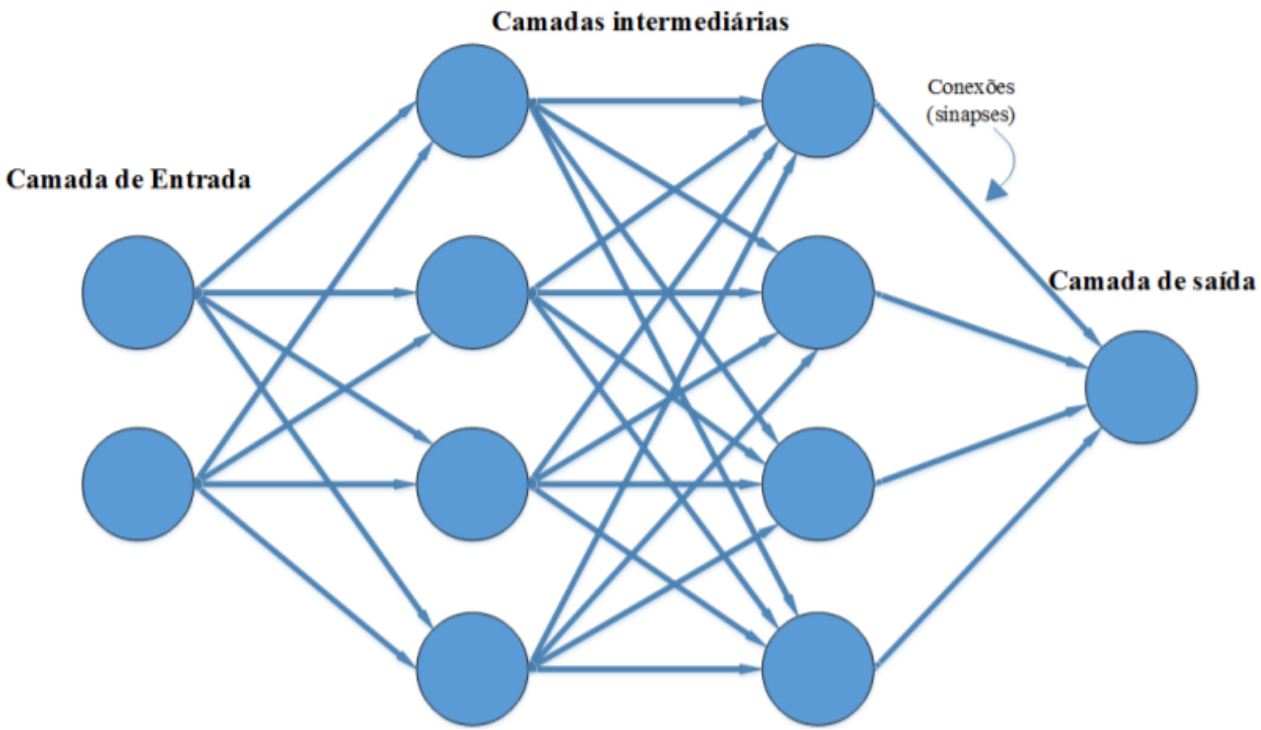

Fonte: [Antonelli and Neitzel, 2015]

Redes Neurais

Redes Neurais

- Redes neurais são agrupamentos de neurônios artificiais
  - Cada um dos neurônios provê um mecanismo simples de processamento;
  - No contexto de redes, neurônios são chamados de nós.
- Redes podem ser arranjadas em camadas (*layers*)
  - A primeira camada, de entrada de dados, é chamada de camada de entrada;
  - As m camadas intermediárias são chamadas de camadas intermediárias ou ocultas;
  - A última camada, de saída da rede, é chamada de camada de saída;

Funcionamento das Redes Neurais

- Funcionamento básico das redes neurais:
  1. Neurônios na camada de entrada recebem entradas para serem classificadas;
  2. As entradas causam o disparo de alguns neurônios (retornam valor acima de um determinado limiar, de acordo com a função de ativação);
  3. Neurônios das camadas iniciais transmitem o sinal para os neurônios das camadas seguintes;
  4. O processo se repete até o final da rede, quando a rede retorna um ou múltiplos valores de saída[3].

[3] Múltiplos valores de saída podem ser utilizados, por exemplo, no processamento de imagens, onde cada saída corresponde a um *pixel* de resultado.

Classificação das Redes Neurais

- Redes de Múltiplas Camadas
  - Redes mais utilizadas, com múltiplas camadas intermediárias;
  - Utilizadas para classificação de padrões, otimização, robótica, controle de processos, etc.
  - Possuem somente uma camada de entrada, *m* camadas intermediárias e uma camada de saída;

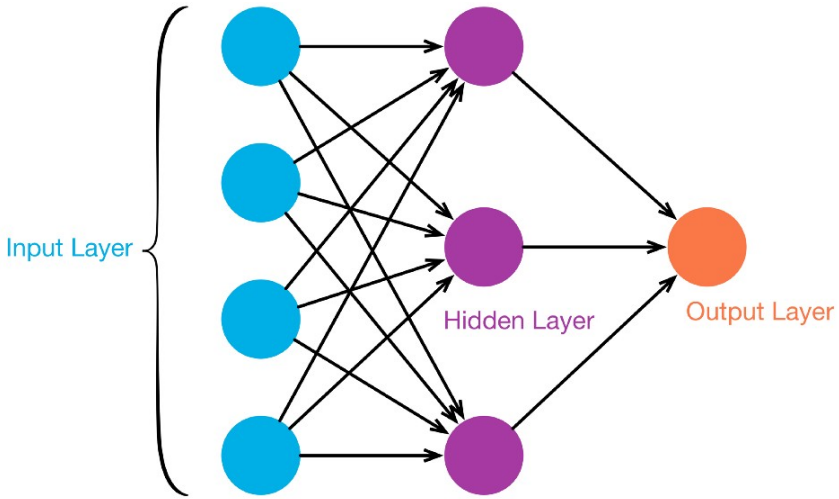

Fonte: [Nahua Kang - Towards Data Science, 2017]

Treinamento de Redes Neurais

- O treinamento das redes neurais são divididos em 2 fases
  - Fase forward
    - Ativações dos neurônios (valores x pesos ativados) são propagadas da entrada para saída;
  - Fase backward
    - A erro/perda entre o valor produzido pela rede e o valor correto é propagado para trás, a fim de modificar pesos e valores de *bias*;
- As fase de propagação para frente e para trás são dependentes [Zhang et al., 2020].

Fundamentos

Tipos de Aprendizado

Classificação quanto a Supervisão

- Aprendizado supervisionado
  - O algoritmo aprende utilizando dados de treinamento pré-rotulados;
  - O algoritmo de treinamento supervisiona a diferença entre as saídas em relação às respostas esperadas;
- Aprendizado não supervisionado
  - O algoritmo aprende a partir de dados não rotulados;
  - Útil em situações onde dados precisam ser classificados ou *clusterizados* em classes ainda indefinidas;

Classificação quanto a Supervisão

- Aprendizado semi supervisionado
  - Intermediário entre o aprendizado supervisionado e o não supervisionado;
  - São fornecidas informações incompletas para treinamento, cabendo ao *software* a decisão sobre o conteúdo não rotulado.
- Aprendizado por reforço
  - Treinamento destinado à interação com ambientes dinâmicos, com objetivo de desempenhar uma ação;
  - O algoritmo recebe uma recompensa (ou premiação), caso atinja o objetivo, ou uma punição, caso falhe;
  - O objetivo é obter o maior valor de recompensa possível.

Classificação quanto a Supervisão

- Aprendizado evolucionário
  - A evolução biológica é definida como processo de aprendizado;
  - Utiliza-se o conceito de *fitness* (adaptação ao ambiente);
  - Organismos mais adaptados sobrevivem, enquanto os menos adaptados perecem [Marsland, 2014].

Classificação x Regressão

Definição

- Classificação: rótulos t_i são definidos por uma quantidade limitada de valores discretos
  - Cada elemento pertence somente a uma classe;
  - O conjunto de classes cobre todo o espaço de saídas possível.
- Regressão: rótulos são definidos como valores contínuos
  - O objetivo da regressão é que a curva/reta se aproxime o máximo possível de todos os pontos;
  - A regressão pode ser um problema de aproximação ou interpolação de funções [Marsland, 2014].

Classificação

- O problema de classificação consiste em tomar um conjunto de elementos e decidir a qual das N classes eles pertencem
  - A classificação é feita com base em um treinamento prévio [Marsland, 2014].

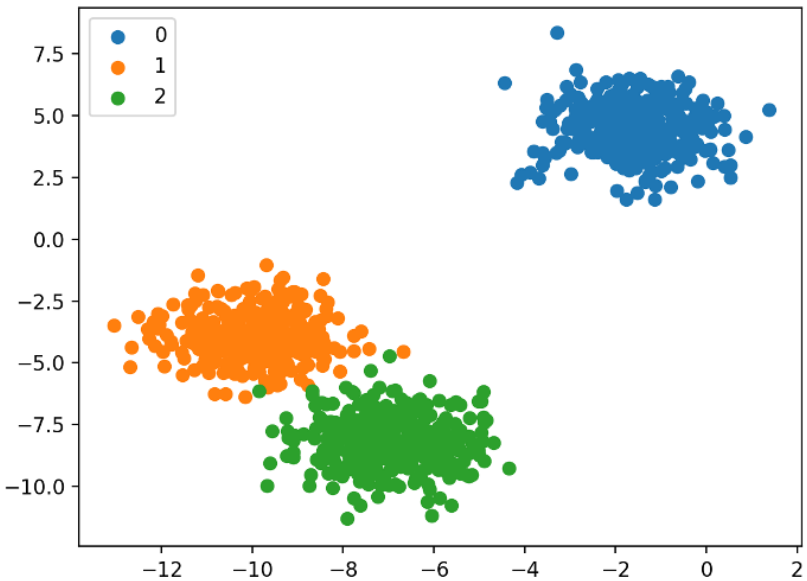

Fonte: [Jason Brownlee - Machine Learning Mastery, 2020]

Regressão

- Regressão é um processo estatístico que busca ajustar uma função matemática para descrever uma curva [Marsland, 2014].

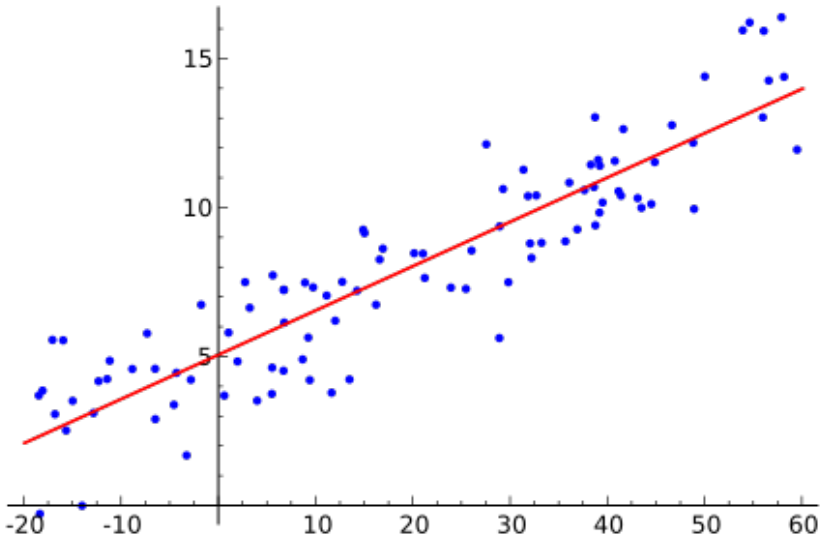

Fonte: [Wikipedia contributors, 2020d]

Treino, Validação e Teste

Conjuntos de Treino, Validação e Teste

- Para treinamento de um algoritmo de aprendizado é apropriado utilizar 3 conjuntos:
  - Conjunto de Treino: destinado efetivamente ao treinamento do algoritmo;
  - Conjunto de Validação: destinado à avaliação de resultados durante a fase de treinamento;
  - Conjunto de Testes: destinado apenas à avaliação de resultados finais.

Proporção entre conjuntos

- Tipicamente utiliza-se a proporção 50:25:25, correspondente a treino, validação e testes;
- Para casos em que há poucos dados, recomenda-se a divisão na proporção 60:20:20 [Marsland, 2014].

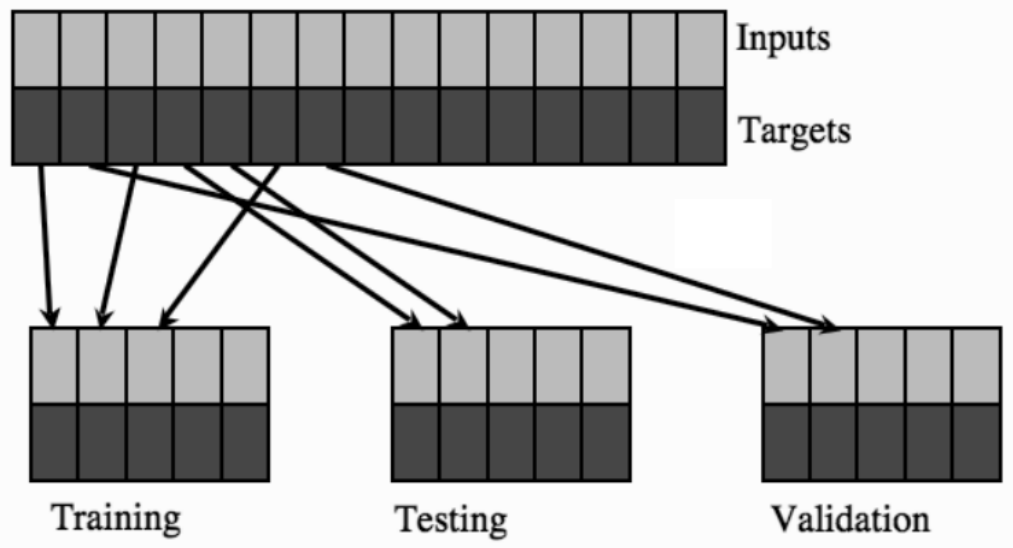

Fonte: [Marsland, 2014]

Recomendação - Conjunto Testes

- **Importante**: O conjunto de testes deve ser utilizado somente após a conclusão de todo o treinamento
  - Não deve ser utilizado durante a fase de treinamento;
  - Deve, ainda, ser utilizado uma única vez.

Otimizadores

Otimizadores

- Otimizadores correspondem aos métodos numéricos utilizados para minimização do erro esperado
  - O objetivo é reduzir a diferença entre a saída predita e a saída esperada;
  - Para isso, devemos minimizar a perda, definindo valores para os pesos da rede;
  - O método mais simples para isso é o *Gradient Descent (GD)*[4], porém esse método tem um custo muito alto
    - Dessa forma o *Gradient Descent* é muito pouco usado.

[4] Também chamado de *Batch Gradient Descent* (BDG) ou *Vanilla Gradient Descent* (VGD).

Stochastic Gradient Descent (SGD)

- O método do gradiente estocástico (SGD) corresponde a uma alteração no método *Gradient Descent*
  - O algoritmo não analisa todos os pontos a serem otimizados, apenas amostras dos dados;
  - O algoritmo varre as amostras e, calcula os valores de gradiente para cada delas;
  - O algoritmo toma a direção de maior declividade dentro das amostras;
  - Essa modificação reduz consideravelmente o custo computacional de cálculo dos gradientes [Ruder, 2016] [Hansen, 2019].

Stochastic Gradient Descent (SGD)

- Como o SGD analisa apenas amostras aleatórias dos dados, seu comportamento é mais instável que o algoritmo GD;
- No entanto, a redução de custo computacional compensa os efeitos colaterais [Ruder, 2016] [Yakout, 2021].

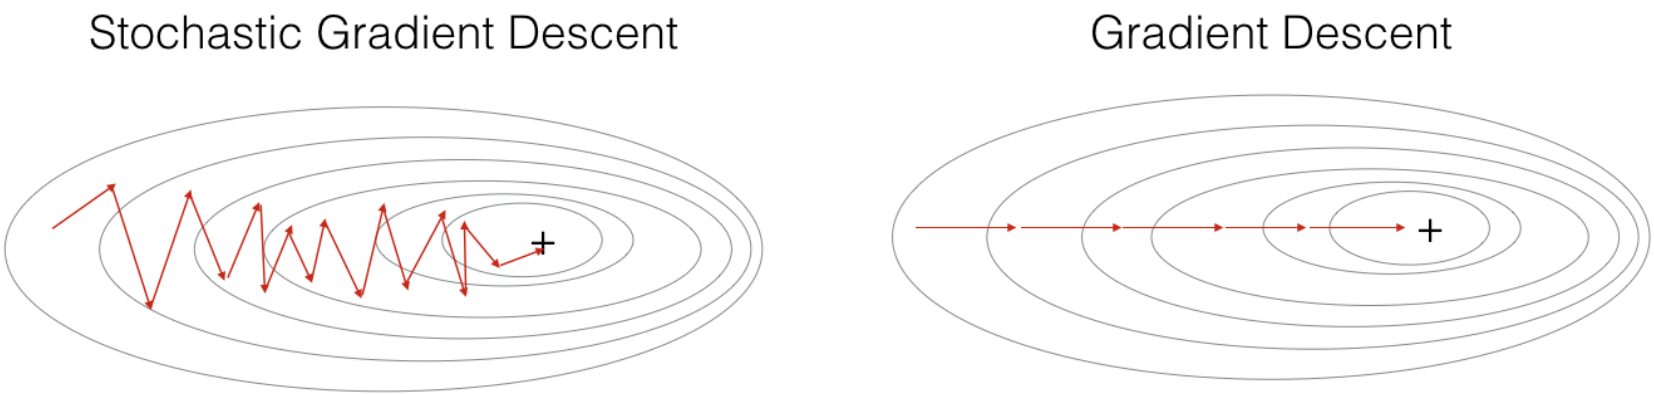

Fonte: [Yakout, 2021]

Momentum

- Momentum é um método para aceleração do otimizadores quando as superfícies da curva convergem mais abruptamente em uma direção do que em outra;
- Seu funcionamento é análogo ao momento em física e auxilia o SGD a manter uma direção fixa [Ruder, 2016].

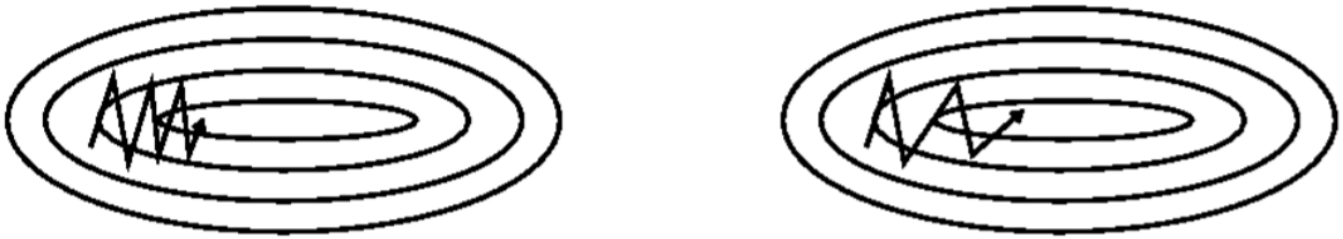

(a) SGD without momentum

(b) SGD with momentum

Fonte: [Ruder, 2016]

Link: animação de um SGD com momentum [Hansen, 2019].

Outros Otimizadores

- Além dos métodos previamente citados (mais simples), destacam-se também na literatura:
  - NAG: acrônimo de Nesterov Accelerated Gradient, tenta dar ao Momentum um tipo de presciência, de forma a dar saltos grandes no início da execução e evitando saltos à medida em que o algoritmo aproxima-se do objetivo [Ruder, 2016];
  - AdaGrad: adapta a taxa de aprendizado aos parâmetros, realizando atualizações maiores para parâmetros pouco frequentes e atualizações menores para parâmetros frequentes [Ruder, 2016].

Link 1: animação de otimizadores para redes neurais [Duong, 2015].

Link 2: animação de otimizadores para redes neurais [Ruder, 2016] [Radford, 2014].

Link 3: animação de otimizadores para redes neurais [Radford, 2014].

Outros Otimizadores

- Outros otimizadores:
  - Adadelta: melhoria do AdaGrad que busca reduzir o decrescimento agressivo e monotônico da taxa de aprendizado, ao reduzir o acúmulo de gradientes passados a uma janela de tempo fixa [Ruder, 2016];
  - RSMprop: método não publicado proposto por Geoffrey Hinton e semelhante ao Adadelta (desenvolvidos separadamente);
  - Adam: acrônimo de Adaptive Moment Estimation, consiste em um método adaptativo para ajuste das taxas de aprendizado, podendo ser considerado uma evolução dos métodos Adadelta/RMSprop e Momentum [Ruder, 2016].

Link 4: animação de otimizadores para redes neurais [Hansen, 2019] [Rahman, 2017].

Link 5: animação de otimizadores para redes neurais [Hansen, 2019] [Rahman, 2017].

Métricas de Desempenho

Métricas de Desempenho

- Além de avaliar a quantidade de dados necessários para testes do algoritmo, é necessário utilizar métricas que indiquem se o resultado é bom ou não [Marsland, 2014];
- Esta seção tem como objetivo descrever as principais métricas de avaliação de desempenho de algoritmos para conjuntos de dados balanceados.

Matriz de Confusão

- A decisão tomada por um classificador pode ser representada por uma estrutura conhecida como matriz de confusão ou tabela de contingência.

		Valor Predito	
		Sim	**Não**
Real	**Sim**	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Fonte: [Nogare, 2020]

	Outputs		
	C_1	C_2	C_3
C_1	5	1	0
C_2	1	4	1
C_3	2	0	4

Fonte: [Marsland, 2014]

Matriz de Confusão

- Segundo [Davis and Goadrich, 2006], matrizes de confusão podem identificar 4 tipos de informação:
  - Verdadeiros Positivos (TP)
    - Valores corretamente classificados como positivos;
  - Falsos Negativos (FN)
    - Valores incorretamente classificados como negativos;
  - Falsos Positivos (FP)
    - Valores incorretamente classificados como positivos;
  - Verdeiros Negativos (TN)
    - Valores corretamente classificados como negativos.

Métricas de Classificação Binária

- A partir da classificação dos resultados, podem ser geradas as seguintes métricas [Fawcett, 2006]:
  - Taxa de Falsos Positivos (FPR)
    - Quantidade de valores incorretamente classificados como positivos, FP, sobre o total de valores negativos, N;

$$\boxed{FPR = \frac{FP}{N}}$$

  - Taxa de Falsos Negativos (FNR)
    - Quantidade de valores incorretamente classificados como negativos, FN, sobre o total de valores positivos, P.

$$\boxed{FNR = \frac{FN}{P}}$$

Métricas de Classificação Binária

- A partir das classificação dos resultados, podem ser geradas as seguinte métricas [Fawcett, 2006]:
  - Taxa de Verdadeiros Positivos (TPR)
    - Quantidade de valores corretamente classificados como positivos, TP, sobre o total de valores positivos, P;

$$\boxed{TPR = \frac{TP}{P}}$$

  - Taxa de Verdadeiros Negativos (TNR)
    - Quantidade de valores corretamente classificados como negativos, TN, sobre o total de valores negativos, N.

$$\boxed{TNR = \frac{TN}{N}}$$

Acurácia

- Podemos considerar as seguintes métricas de acurácia:
  - Acurácia
    - Quantidade de verdadeiros Positivos, TP, somado à quantidade verdadeiros negativos, TN, dividido pelo número de amostras [Fawcett, 2006];

$$\boxed{acurácia = \frac{TP + TN}{P + N}}$$

  - Taxa de Erro[5]
    - Número de valores positivos e negativos classificados incorretamente sobre soma total de valores [Guo et al., 2012].

$$\boxed{ER = \frac{FP + FN}{P + N}}$$

[5] *Error Rate* (ER).

Acurácia

- **Importante**: Para uso da métrica acurácia, devemos assumir, implicitamente, a existência da mesma quantidade de exemplos positivos e negativos
  - Esse conjunto de dados é conhecido como balanceado [Marsland, 2014].

- Ex.: Considere o algoritmo abaixo, para detecção de uma doença X, onde somente 1% dos indivíduos analisados estão efetivamente doentes
  - Esse algoritmo possui acurácia de 99%, no entanto, é incapaz de identificar um único paciente doente.

```
bool pacienteEstaDoente(){
    return False;
}
```

Fonte: Próprio autor

Precisão e Revocação

- Precisão[6] e Revocação[7] são métricas de classificação binária frequentemente usadas em Aprendizado de Máquinas;
  - Precisão (*precision*)
    - Mede a proporção de eventos de modelo que são verdadeiros;

$$\boxed{precisão = \frac{TP}{TP + FP}}$$

  - Revocação (*recall*)
    - Mede a proporção de eventos que ocorrem no domínio que são capturados pelos modelos [Fawcett, 2006].

$$\boxed{revocação = \frac{TP}{TP + FN}}$$

[6] Denominado também por Valor Predito Positivo.

[7] Denominado também por Sensibilidade.

Precisão e Revocação

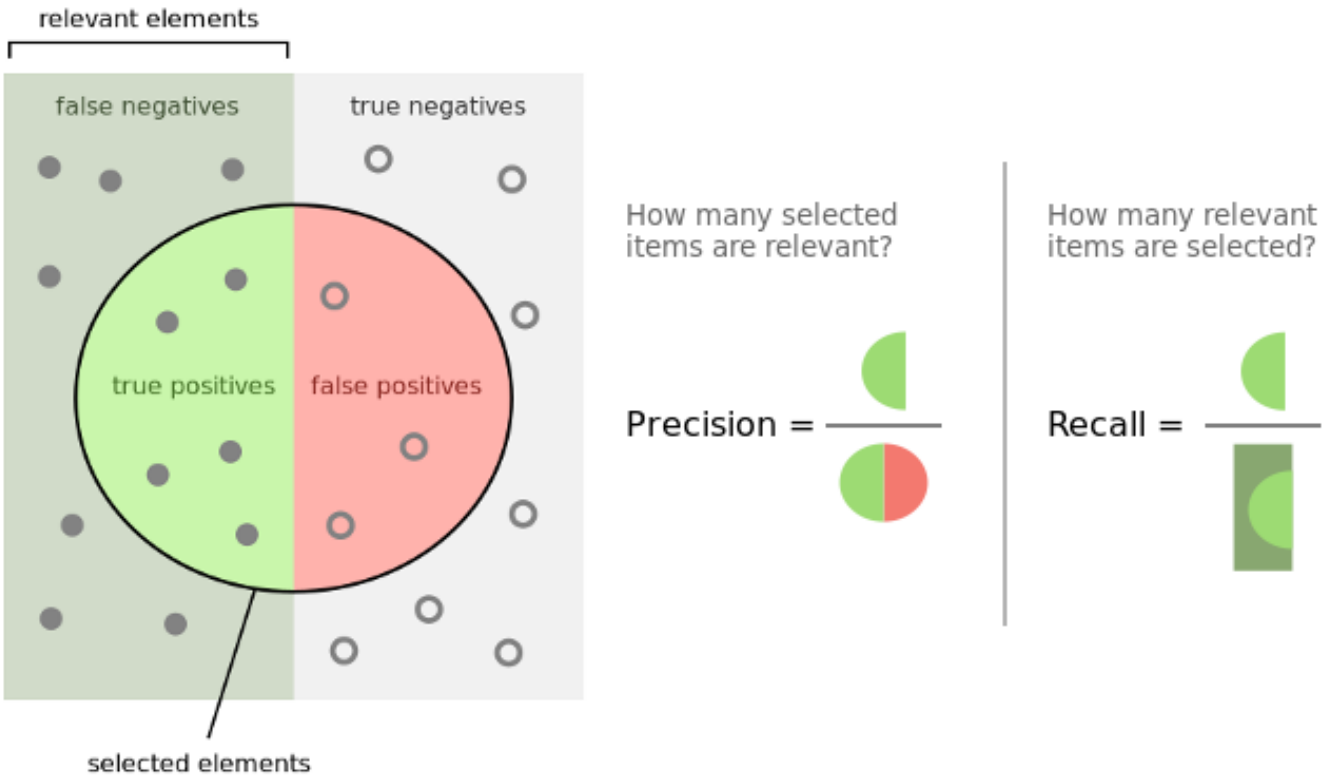

Fonte: [Wikipedia contributors, 2020b]

F-measure

- Para uma matriz de confusão simples, a *F-measure*[8], é uma média harmônica entre a precisão e a revocação;
  - Busca balancear a importância de precisão e revocação;
  - Quando ambas possuem valores próximos, a métrica equivale a aproximadamente a média das duas medidas;

$$\boxed{\textit{F-measure} = \frac{2 \cdot \textit{precisão} \cdot \textit{revocação}}{\textit{precisão} + \textit{revocação}}}$$

[8] Também chamada de *F-score* ou F_1 *measure* [Marsland, 2014].

Redes Convolucionais

Redes Convolucionais

- Redes convolucionais (CNNs) são compostas por camadas com convoluções, operações de *pooling* e funções de ativação ReLU (nas camadas intermediárias);
- Dependendo do objetivo, podem ser utilizadas camadas totalmente conectadas no final da rede [Li et al., 2021].

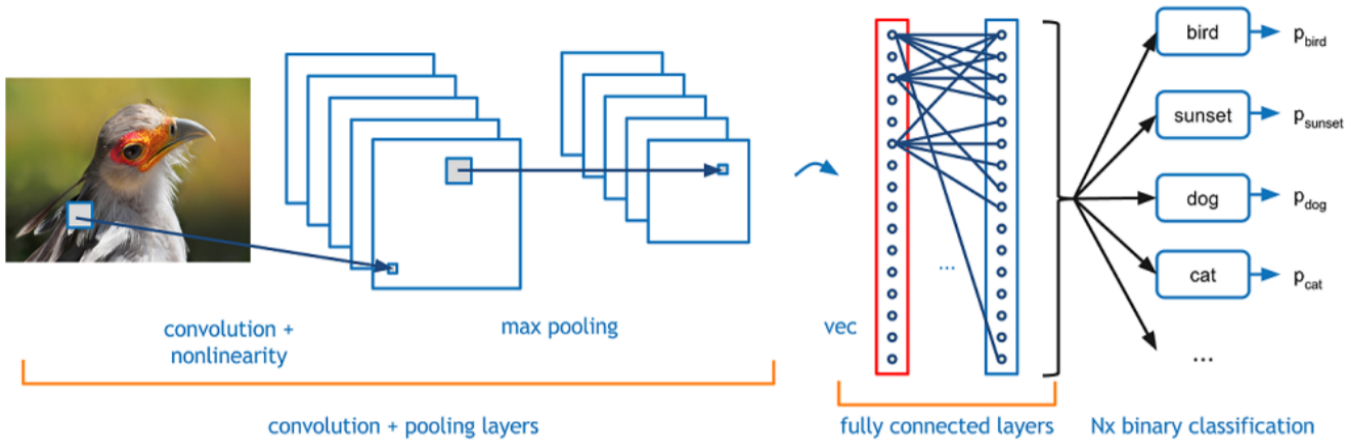

Fonte: [Florindo, 2018]

Redes Convolucionais

- Em geral, as redes convolucionais trabalham com imagens
  - Com isso, a arquitetura pode conter algumas restrições não existentes em redes tradicionais;
- Ao contrário de redes convencionais, redes convolucionais possuem neurônios organizados em 3 dimensões:
  - As dimensões são: largura, altura e profundidade[9];
  - Essa característica é especialmente útil no processamento de imagens;
  - Imagens possuem altura, largura e, em geral, 3 canais de cores [Li et al., 2021].

[9] Tradução do inglês: *width*, *height* e *depth*.

Redes Convolucionais

- Ao contrário das redes totalmente conectadas:
  - Os neurônios em uma camada são conectados apenas a uma pequena região da camada anterior;
  - A rede transforma a entrada 3D em um "volume" 3D de ativações de neurônios;
  - No final de algumas redes existem camadas de achatamento (*flatten*) e/ou camadas totalmente conectadas, para produzir predições [Li et al., 2021].

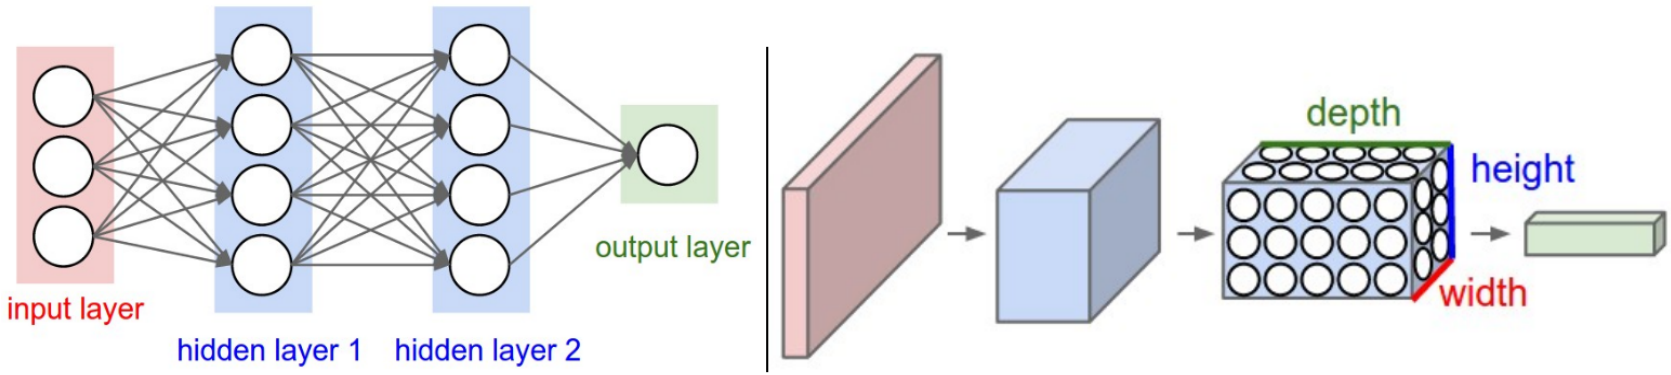

Fonte: [Li et al., 2021]

Convolução

Operação de Convolução

- A convolução é a operação mais importante em uma rede convolucional;
- Consiste em um operador linear para duas funções f e g;
- Resulta em um terceiro valor s, que mede a soma do produto ao longo da região subentendida pela superposição de g, quando deslocada sobre uma função f [Weisstein, 2018].

$$(f * g)(t) = s(t) = \int_{-\infty}^{\infty} f(u) \cdot g(t-u) du$$

Operação de Convolução

- A convolução pode ser entendida como a forma com que um sistema opera sobre um sinal de entrada [Smith, 1997].

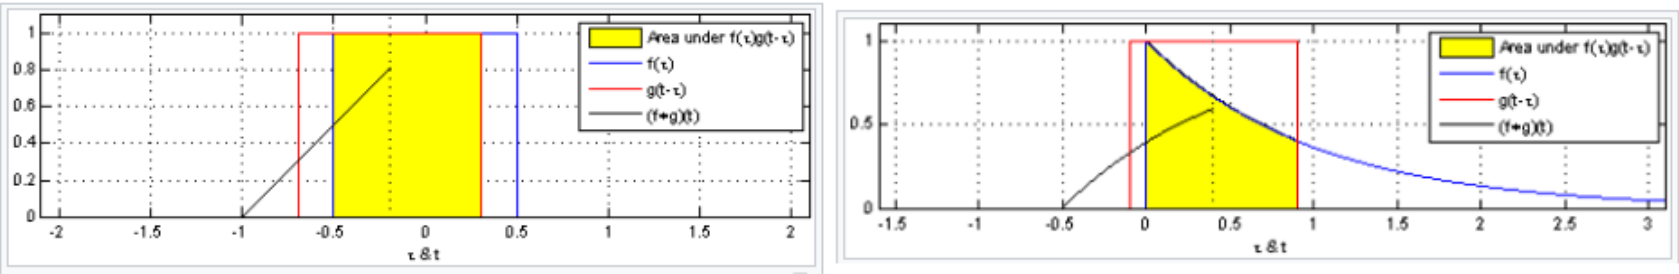

Fonte: Adaptado de [Wikipedia contributors, 2020a]

Link: animação de uma convolução 1 [Wikipedia contributors, 2020a]

Link: animação de uma convolução 2 [Wikipedia contributors, 2020a]

Operação de Convolução

- Na terminologia de redes convolucionais, a função f corresponde a entrada, g representa o *kernel* e a saída s corresponde ao mapa de saída (*feature map*);
- Segundo [Goodfellow et al., 2016], as convoluções são utilizadas para aprimorar resultados nos seguintes campos:
  - Interações esparsas: possibilitam o armazenamento de características importantes com baixo número de parâmetros;
  - Compartilhamento de parâmetros: possibilita armazenamento apenas de alguns valores, que geram os demais pesos da rede;
  - Representações equivariantes: alterações realizadas na entrada produzem efeitos correspondentes nas saídas.

Camada Convolucional

- Principal camada das redes convolucionais, responsável pela maior parte dos cálculos [Li et al., 2021];
- Convoluções utilizam múltiplos filtros (*kernels*), que podem ter diferentes tamanhos (ex.: $5 \times 5 \times 3$, $32 \times 32 \times 3$, etc);
- Durante o *forward pass*, é feita a convolução de cada filtro na largura e altura do volume de entrada;
- Em seguida, são calculados os produtos escalares entre as entradas do filtro e a entrada em qualquer posição [Li et al., 2021].

Camada Convolucional

- Os filtros são "deslizados" sobre largura e altura do volume;

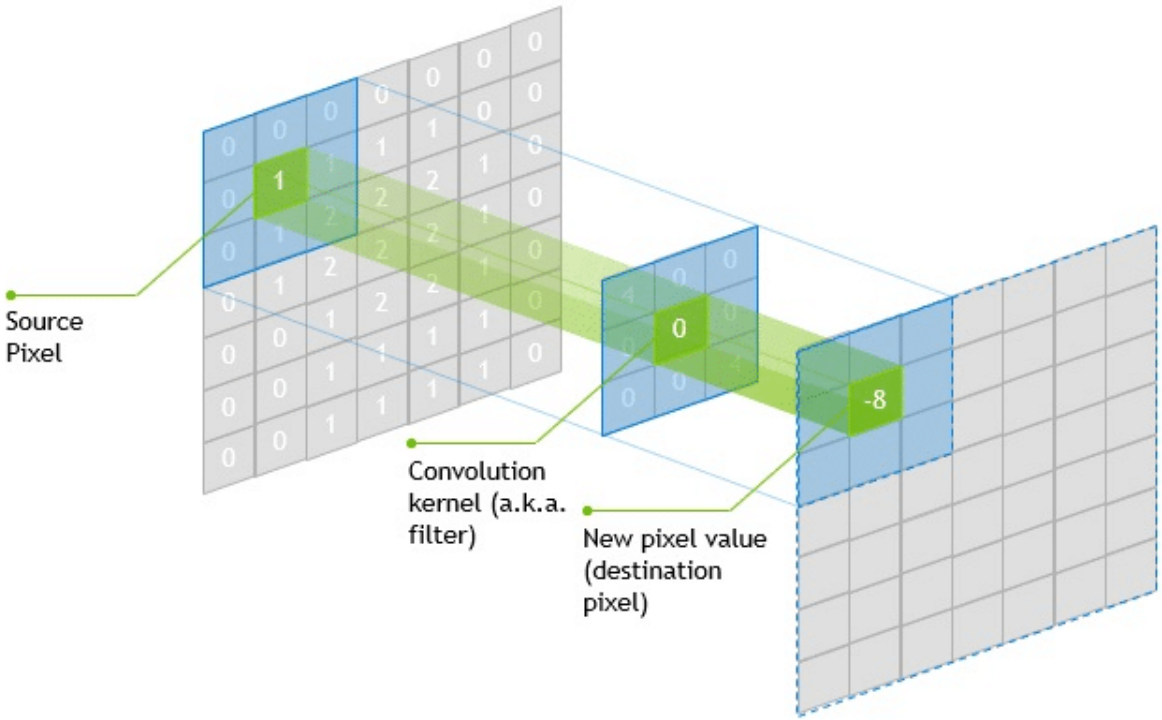

Fonte: [Martin, 2018]

Camada Convolucional

- Produz-se um mapa de ativação bidimensional que fornece as respostas desse filtro em cada posição espacial;
- A rede aprende quais filtros ativar a partir das entradas;
- Os filtros ativados são empilhados na camada de profundidade para produção do volume de saída [Li et al., 2021].

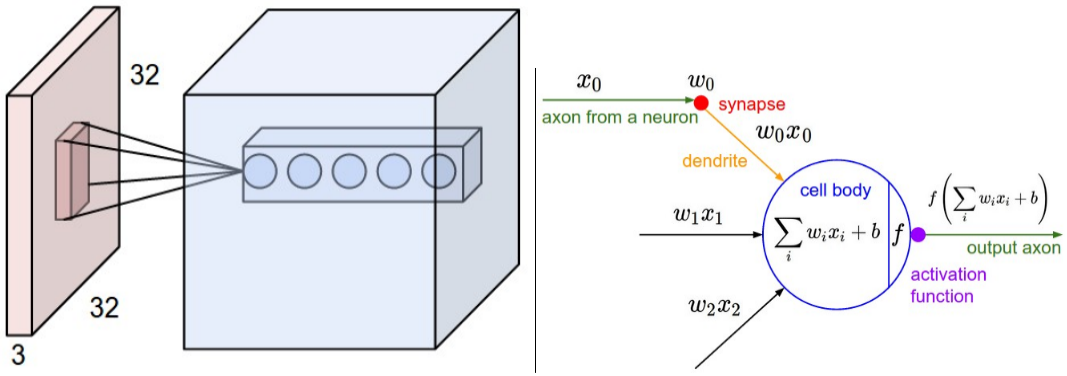

Fonte: [Li et al., 2021]

Link: Animação com o funcionamento de uma convolução [Li et al., 2021].

Camada Convolucional

- A aplicação de múltiplos filtros (*kernels*) convolucionais dá origem a uma profundidade diferente na camada seguinte [Li et al., 2021].

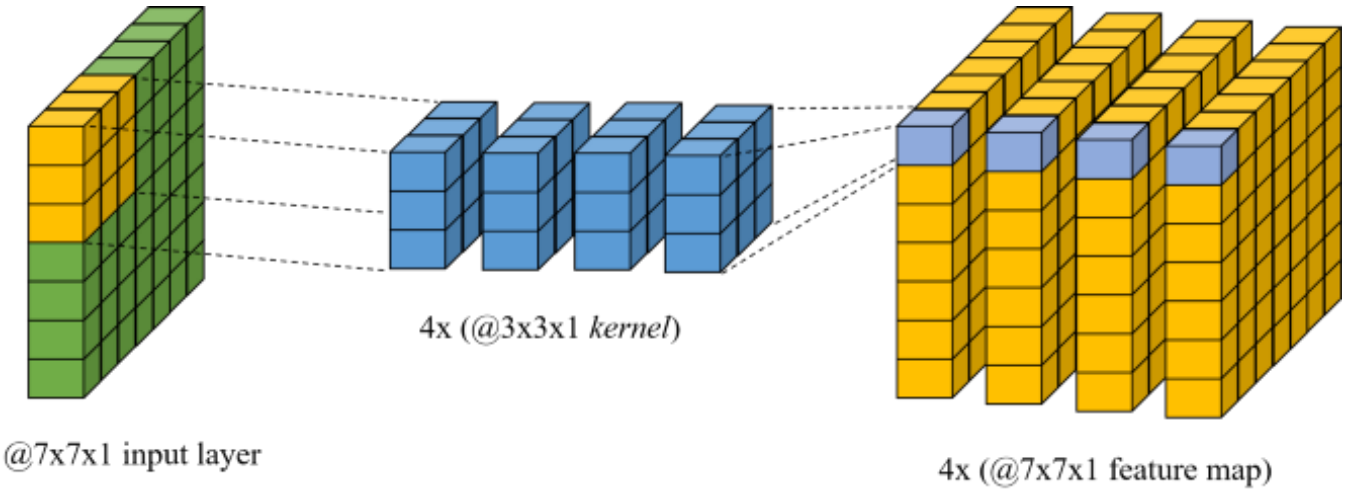

Fonte: [Yunus, 2020]

Link: Animação com o funcionamento de uma convolução [Li et al., 2021].

Profundidade, *Stride* e *Zero-padding*

- O tamanho do volume, é definido por 3 parâmetros:
  - Profundidade (*depth*): hiperparâmetro correspondente ao número de *kernels* que serão utilizados para criação de mapas de características
    - Cada filtro pode aprender características diferentes, como cores, texturas e variações de tonalidade;
  - *Stride*: taxa de "deslizamento" dos *kernels*, em *pixels*;
  - *Zero-padding*[10]: corresponde ao à quantidade de zeros adicionados às bordas da imagem para melhor ajuste de tamanho (*pad*) [Li et al., 2021] [IBM, 2020].

[10] Frequentemente denominado apenas como *padding*, pode ser traduzido como preenchimento de zeros.

Pooling

Pooling

- A função de *pooling* é utilizada para prover informação estatística a respeito das saídas próximas;
- Tem como objetivo maximizar as vantagens da saída e tornar-se invariante a pequenos ruídos;
- Podem também ser utilizadas para redução da quantidade de neurônios entre camadas da rede, agrupando resultados na camada seguinte [Goodfellow et al., 2016].

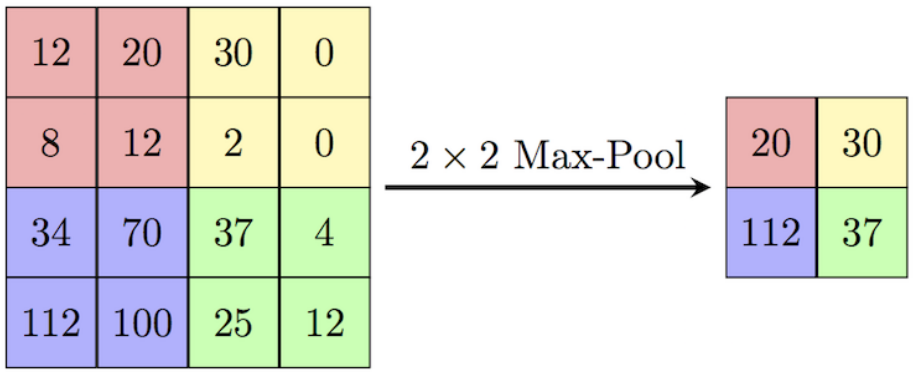

Fonte: [Computer Science Wiki, 2020]

Pooling

- A operação de *pooling* é executada em cada camada do volume, promovendo redução de dimensionalidade;

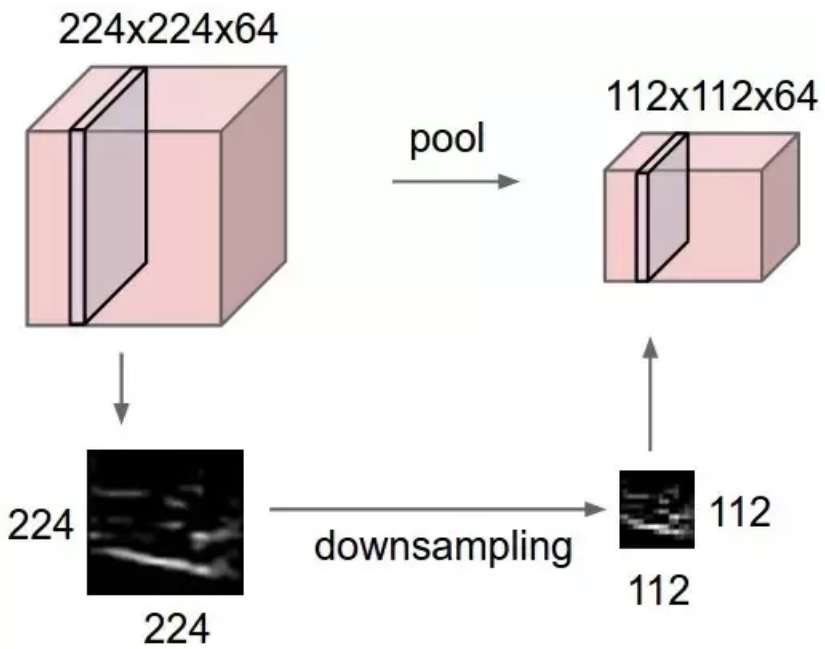

Fonte: [Computer Science Wiki, 2020]

Pooling

- Os tipos de pooling mais comuns são:
  - Max-pooling: utiliza operação de máximo no filtro de *pooling*
    - Tipo mais utilizado de *pooling*, presente em redes como a VGGNet e AlexNet;
    - Capaz de selecionar os *pixels* mais ativados localmente, descartando *pixels* com valores baixos;
    - Capaz de representar uma região, por meio das informações mais importantes;
  - Avg-pooling: utiliza a operação de média no filtro de *pooling*
    - Capaz de representar uma região, por meio de informações médias;
    - Menos comum que *max-pooling*, mas presente na rede ResNet.

Função de Ativação ReLU

ReLU

- ReLU: *Rectified linear unit* (Unidade linear retificada);
- Função de ativação empregada em redes neurais convolucionais, principalmente em camadas intermediárias;
- Vantagens:
  - Melhor propagação de gradientes: diminuição da quantidade de gradientes que tendem a zero devido ao acúmulo de camadas e pequenos valores, quando comparado a função sigmoide;
  - Invariante a escala: $max(0, ax) = a\ max(0, x)$ para $a \geq 0$;
  - Ativação esparsa: em redes inicializadas aleatoriamente, somente 50% das camadas intermediárias são ativadas;

ReLU

- A função ReLU é definida formalmente como:

$$f(x) = max(0, x)$$

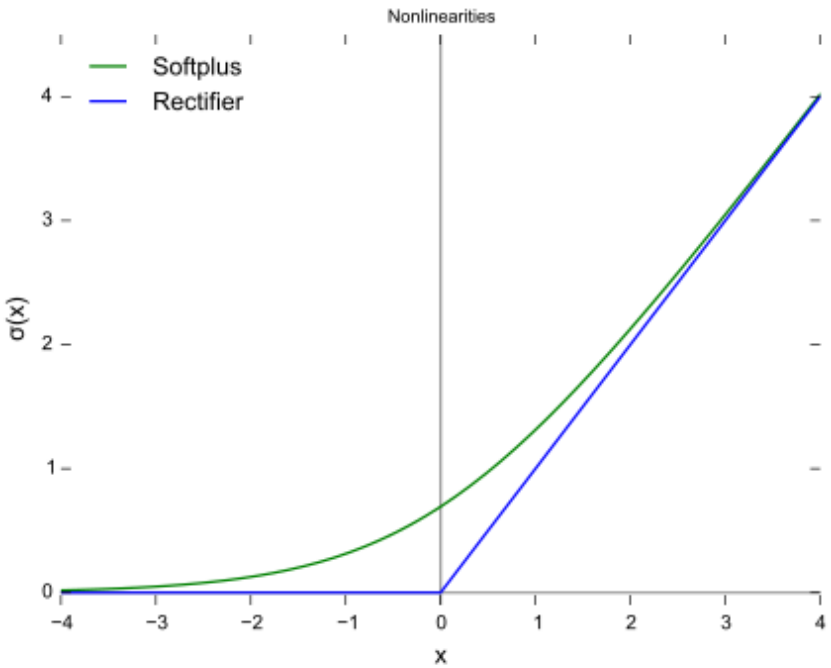

Fonte: [Wikipedia contributors, 2020c]

Referências I

Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., and Zheng, X. (2015).
TensorFlow: Large-scale machine learning on heterogeneous systems.
Software available from tensorflow.org.

Antonelli, G. and Neitzel, I. (2015).

Aplicação de redes neurais artificiais na indústria de fios de algodão: Determinação do Índice de fibras imaturas.
Revista Gestão Industrial, 11.

Chollet, F. (2015).

keras.
`https://github.com/fchollet/keras`.
[Online]; acessado em 17 de outubro de 2021. Disponível em `https://keras.io/`.

Computer Science Wiki (2020).

Max-pooling / pooling.
[Online]; acessado em 08 de Setembro de 2020. Disponível em:
`https://computersciencewiki.org/index.php/Max-pooling_/_Pooling`.

Coppin, B. (2004).

Artificial intelligence illuminated.
Jones and Bartlett illuminated series. Jones and Bartlett Publishers, 1 edition.

Referências II


da Silva, D. M. (2014).
Inteligência Artificial - Slides de Aula.
IFMG - Instituto Federal de Minas Gerais, Campus Formiga.


Davis, J. and Goadrich, M. (2006).
The relationship between precision-recall and roc curves.
In Proceedings of the 23rd International Conference on Machine Learning, ICML '06, pages 233–240, New York, NY, USA. ACM.


Duong, H. (2015).
Gradient descent and variants - convergence rate summary.
[Online]; acessado em 03 de Setembro de 2020. Disponível em:
http://hduongtrong.github.io/2015/11/23/coordinate-descent/.


Elshawi, R., Wahab, A., Barnawi, A., and Sakr, S. (2021).
Dlbench: a comprehensive experimental evaluation of deep learning frameworks.
Cluster Computing, 24(3):2017–2038.


Fawcett, T. (2006).
An introduction to roc analysis.
Pattern Recognition Letters, 27(8):861 – 874.
ROC Analysis in Pattern Recognition.


Florindo, J. a. B. (2018).
Redes neurais convolucionais.
[Online]; acessado em 08 de Setembro de 2020. Disponível em:
https://www.ime.unicamp.br/~jbflorindo/Teaching/2018/MT530/T10.pdf.

Referências III

Goodfellow, I., Bengio, Y., and Courville, A. (2016).

Deep Learning.

MIT Press.

[Online]; acessado em 17 de outubro de 2021. DisponÃvel em: http://www.deeplearningbook.org.

Google Trends (2020).

Deep learning.

[Online]; acessado em 25 de Agosto de 2020. Disponível em:
https://trends.google.com.br/trends/explore?date=all&q=deep%20learning.

Guo, C., Mita, S., and McAllester, D. (2012).

Robust road detection and tracking in challenging scenarios based on markov random fields with unsupervised learning.

IEEE Transactions on Intelligent Transportation Systems, 13(3):1338–1354.

Hale, J. (2018).

Deep learning framework power scores 2018.

[Online]; acessado em 17 de outubro de 2021. Disponível em
https://towardsdatascience.com/deep-learning-framework-power-scores-2018-23607ddf297a.

Hansen, C. (2019).

Optimizers explained - adam, momentum and stochastic gradient descent.

[Online]; acessado em 27 de Janeiro de 2021. Disponível em:
https://mlfromscratch.com/optimizers-explained/#/.

Referências IV

IBM (2020).

Convolutional neural networks.
[Online]; acessado em 26 de Janeiro de 2021. Disponível em:
https://www.ibm.com/cloud/learn/convolutional-neural-networks.

Jason Brownlee - Machine Learning Mastery (2020).

4 types of classification tasks in machine learning.
[Online]; acessado em 17 de outubro de 2021. Disponível em
https://machinelearningmastery.com/types-of-classification-in-machine-learning.

Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012).

Imagenet classification with deep convolutional neural networks.
In Proceedings of the 25th International Conference on Neural Information Processing Systems - Volume 1, NIPS'12, pages 1097–1105, Red Hook, NY, USA. Curran Associates Inc.

Li, F.-F., Krishna, R., and Xu, D. (2021).

Convolutional neural networks (cnns / convnets).
[Online]; acessado em 26 de Janeiro de 2021. Disponível em:
https://cs231n.github.io/convolutional-networks/.

Marsland, S. (2014).

Machine Learning: An Algorithm Perspective.
CRC Press, 2 edition.
Disponível em: https://homepages.ecs.vuw.ac.nz/ marslast/MLbook.html.

Referências V

Martin, S. (2018).

What's the difference between a cnn and an rnn?
[Online]; acessado em 26 de Janeiro de 2021. Disponível em:
https://blogs.nvidia.com/blog/2018/09/05/whats-the-difference-between-a-cnn-and-an-rnn/.

Nahua Kang - Towards Data Science (2017).

Multi-layer neural networks with sigmoid functionâ deep learning for rookies.
[Online]; acessado em 01 de Setembro de 2020. Disponível em: https://towardsdatascience.com/multi-layer-neural-networks-with-sigmoid-function-deep-learning-for-rookies-2-bf464f09eb7f.

Nogare, D. (2020).

Performance de machine learning - matriz de confusão.
Disponível em http://diegonogare.net/2020/04/performance-de-machine-learning-matriz-de-confusao/.

Piatetsky, G. (2018).

Python eats away at r: Top software for analytics, data science, machine learning in 2018: Trends and analysis.
[Online]; acessado em 17 de outubro de 2021. Disponível em https://www.kdnuggets.com/2018/05/poll-tools-analytics-data-science-machine-learning-results.html/2.

Radford, A. (2014).

Visualizing optimization algos.
[Online]; acessado em 27 de Janeiro de 2021. Disponível em: https://imgur.com/a/Hqolp.

Referências VI


Rahman, R. (2017).
Visualising stochastic optimisers.
[Online]; acessado em 27 de Janeiro de 2021. Disponível em:
https://rnrahman.com/blog/visualising-stochastic-optimisers/.


Ruder, S. (2016).
An overview of gradient descent optimization algorithms.
CoRR, abs/1609.04747.


Russel, S. and Norvig, P. (2013).
Inteligência artificial.
Campus - Elsevier, 3 edition.


Sadek Alaoui - SQLML (2017).
Convolutional neural network.
[Online]; acessado em 25 de Agosto de 2020. Disponível em:
http://sqlml.azurewebsites.net/2017/09/12/convolutional-neural-network/.


Smith, S. W. (1997).
The Scientist and Engineer's Guide to Digital Signal Processing.
California Technical Publishing, San Diego, CA, USA.
http://www.dspguide.com.


Weisstein, E. W. (2018).
Convolution.
http://mathworld.wolfram.com/Convolution.html.

Referências VII


Wikipedia contributors (2020a).
Convolution.
[Online]; acessado em 08 de Setembro de 2020. Disponível em: https://en.wikipedia.org/wiki/Convolution.


Wikipedia contributors (2020b).
Precision and recall.
[Online]; acessado em 17 de outubro de 2021. Disponível em https://en.wikipedia.org/wiki/Precision_and_recall.


Wikipedia contributors (2020c).
Rectifier (neural networks).
[Online]; acessado em 08 de Setembro de 2020. Disponível em: https://en.wikipedia.org/wiki/Rectifier_(neural_networks).


Wikipedia contributors (2020d).
Regression analysis.
[Online]; acessado em 17 de outubro de 2021. Disponível em https://en.wikipedia.org/wiki/Regression_analysis.


Yakout, A. (2021).
Coursera deep learning specialization by andrew ng.
[Online]; acessado em 27 de Janeiro de 2021. Disponível em: https://yakout.io/deeplearning/coursera-deep-learning-course-2-week-2/.

Referências VIII

Yunus, M. (2020).

11 artificial neural network (ann) â part 6 konsep dasar convolutional neural network (cnn).
[Online]; acessado em 26 de Janeiro de 2021. Disponível em: https://yunusmuhammad007.medium.com/11-artificial-neural-network-ann-part-6-konsep-dasar-convolutional-neural-network-cnn-3cc10fd9cf6

Zhang, A., Lipton, Z. C., Li, M., and Smola, A. J. (2020).

Dive into Deep Learning.
https://d2l.ai.